

# Weakly Supervision Twitter Profile

Speaker: @cymph

September 10, 2014

"Weakly Supervised User Profile Extraction from Twitter"

Jiwei Li, Alan Ritter, Eduard Hovy, 2014

を読みます .

"Weakly Supervised User Profile Extraction from Twitter"  
Jiwei Li, Alan Ritter, Eduard Hovy, 2014  
を読みます .

- Twitter ユーザーの個人情報の推定

"Weakly Supervised User Profile Extraction from Twitter"

Jiwei Li, Alan Ritter, Eduard Hovy, 2014

を読みます .

- Twitter ユーザーの個人情報の推定
- 友達の推薦、広告とかに使える

## "Weakly Supervised User Profile Extraction from Twitter"

Jiwei Li, Alan Ritter, Eduard Hovy, 2014

を読みます。

- Twitter ユーザーの個人情報の推定
- 友達の推薦、広告とかに使える
- 実際、性別による広告ターゲティングが使われてる ("広告主の方へ：Twitter プロモ商品で性別のターゲティングが可能になりました")

## "Weakly Supervised User Profile Extraction from Twitter"

Jiwei Li, Alan Ritter, Eduard Hovy, 2014

を読みます .

- Twitter ユーザーの個人情報の推定
- 友達の推薦、広告とかに使える
- 実際、性別による広告ターゲティングが使われてる (" 広告主の方へ：Twitter プロモ商品で性別のターゲティングが可能になりました")
- (個人的に) ネットストが効率化される

## リンク

- <http://aritter.github.io/> 作者の一人のサイト
- <http://www.aclweb.org/anthology/P/P14/P14-1016.pdf>  
論文はここ

# 目次

- 1 導入
- 2 関連研究
- 3 データ
- 4 モデル
  - 推定
- 5 実験



ユーザーのツイートと友達関係からそのユーザーの (Facebookっぽい) プロフィールを生成する

- 配偶者
- 学歴 (在学してる大学)
- 職業
- 趣味
- 宗教
- 出身地
- 現住所
- 家族

ユーザーのツイートと友達関係からそのユーザーの (Facebookっぽい) プロフィールを生成する

- 配偶者
- 学歴 (在学してる大学)
- 職業
- 趣味
- 宗教
- 出身地
- 現住所
- 家族

ツイートの中で言及があれば、強い証拠になる．というか、そのような言及はありと仮定する．

### 配偶者 (の Twitter ID)

@hogehoge has taken all the kids today so I can go shopping - CHILD FREE!

### 学歴 (学校の名前)

I got accepted to be part of the UofM engineering safety pilot program in FSU.

### 職業 (会社名)

first day of work at HuffPo, a sports bar woo come visit me yo..

# 先行研究

- Twitter のプロフィール当ての先行
  - 年齢 – Rao+ 2010
  - 政治的意見 (極性) – Pennacchiotti & Popescu 2011, Conovt+ 2011
  - 性別 – Ciot+ 2013, Liu & Ruth 2013, Liu+2012
- 訓練データの作成のコスト
  - 例えば上の Cio+ 2013 は、プロフィール画像を人間が見て手で性別を書きだした

# 知見

- Distant supervision a.k.a. weak supervision
  - 後述
- Homophily
  - (ネットにおける) 友達関係は同じ属性 (趣味とか) を持ちやすい
  - 今回の場合、「学歴」「職業」についてはかなり利きそう
  - 逆に「配偶者」については全く効かなそう
  - 属性の性質によって恣意的に

# Distant supervision

"Distant supervision for relation extraction without labeled data"

Mintz+, 2009

<http://web.stanford.edu/~jurafsky/mintz.pdf>

訓練データの作成に手でラベルを付与する代わりに、知識データベース (e.g. Freebase<sup>1</sup>) を間に挟んで手間を省く。

---

<sup>1</sup><http://www.freebase.com/>

# 訓練データの作成

## 3つの属性

- 学歴
- 職業
- 配偶者

について、それぞれ、Twitter ID をノードとするグラフを3つ作る。(一つのユーザーについて3つの属性を揃えるわけではない)

学歴、職業、については  
 Google+ を用いる。  
 最終的に Twitter ID と紐付け  
 したいので、

- (「学歴」or
- 「職業」) and
- 「Twitter へのリンク」

を満たすプロフィールページ  
 を探す。



The screenshot shows a Google+ profile with the following sections:

- 教育 (Education):**
  - 東京大学大学院情報理工学系研究科 (Graduate School of Information Science and Technology, University of Tokyo)
  - コンピュータ科学専攻, 2013 - 現在 (Computer Science Major, 2013 - Present)
  - 東京大学 (University of Tokyo)
  - 理学部情報科学科, 2009 - 2013 (Department of Information Science, Faculty of Science, 2009 - 2013)
  - 滋賀県立膳所高校 (Suzuka High School, Shiga Prefecture)
  - 2006 - 2009
- 現在 (Current Location):**
  - 東京都文京区 (Bunkyo Ward, Tokyo)
- リンク (Links):**
  - Twitter: [@Hogehoge](#)
- 基本情報 (Basic Information):**
  - 性別 男性 (Gender: Male)

Google+ "knowledge base"



# エイリアス

データベースである Freebase  
を用いる

"Harvard University"

"Harvard" "Harvard U"

→ 何か一つ

**Freebase** is an open, [Creative Commons](#) licensed [graph database](#) with more than **23 million entities**.

An **entity** is a single person, place, or thing. Freebase connects entities together as a [graph](#).

Ways to use Freebase:

- Use Freebase's **Ids** to uniquely identify entities anywhere on the web
- **Query** Freebase's data using [MQL](#)
- Build **applications** using our [API](#) or [Acre](#), our hosted development platform

# データの広げ方

Google+, Twitter の友達関係の両方を用いて、ユーザーを追加してく．

ただし、Twitter の友達関係は、あとで素性として使う．

# 配偶関係

配偶者をわざわざ書かせる  
SNS は Facebook くらいしか  
ないので、これを用いる。  
ただしこれだけだと少ないの  
で Freebase を用いて  
/PEOPLE/PERSON/SPOUSE に  
あるものを追加する。

http:

//www.freebase.com/people/marriage?instances=

148,116 /people/marriage mediators

To	From	Spouse
7/1/2011	4/26/1986	Maria Shriver Arnold Schwarzenegger
	8/28/2004	Michelle Hlubinka Robert Cook
2014 March	7/28/1983	Lyudmila Putina Vladimir Putin
1958	8/11/1950	Verena Huber-Dyson Freeman Dyson
	11/21/1958	Imme Dyson Freeman Dyson
5/29/1958	9/14/1939	Theodora Lynch J. Paul Getty
1935	12/1/1932	Ann Rork J. Paul Getty
8/4/1932	12/31/1928	Adolp hine Helmle J. Paul Getty
1928	1926	Allene Ashby J. Paul Getty
9/6/1973	12/6/1962	Diane Cillerio Sean Connery
	5/6/1975	Micheline Roquebrune Sean Connery

また配偶関係は反射関係を持つはず

$$a \text{ isSpouseOf } b = b \text{ isSpouseOf } a$$

ことから,

$a \text{ isSpouseOf } b$  かどうかが分からなくても、  
 $b \text{ isSpouseOf } a$  が分かれば、そちらも決定できる .

# データの統計

以上のように集めたデータセットを正のデータとする．異なる組み合わせを負のデータとして作る．

	Education	Job	Spouse
#Users	7,208	1,806	1,636
#Pos Entities	451	380	3121
#Neg Entities	7.0e6	4.4e6	8.8e6

Table 2 の一部

提案されるモデル

# 変数

- ユーザー:  $1 \leq i, j \leq M$
- 属性:  $k = \text{Spouse, Education, Job}$
- ユーザー  $i$  によるツイート (集合):  $X_i = \{x_{i,j}\}$
- エンティティ:  $e$  (属性問わず)
- ユーザー  $i$  の属性  $k$  についての友達の集合:  $F_i^k$ 
  - $k = \text{Education, Job}$  の場合は単なるフォロー関係
  - $k = \text{Spouse}$  の場合は、配偶者の単集合
- $z_{i,e}^k$ : ユーザー  $i$  の属性  $k$  が  $e$  であるかどうか
- $z_{i,x}^k$ : ユーザー  $i$  のツイート  $x$  が属性  $k$  についての言及であるかどうか

# 戦略

**GLOBAL**  $z_{i,e}^k$ : ユーザー  $i$  の属性  $k$  が  $e$  であるかどうか

**LOCAL**  $z_{i,x}^k$ : ユーザー  $i$  のツイート  $x$  が属性  $k$  についての言及であるかどうか

最終的には  $z_{i,e}^k$  を知りたい.

**GLOBAL** は直接それを推定する.

**LOCAL** はツイートの単位で  $z_{i,x}^k$  を推定する. 最後に OR をとれば、

$$z_{i,e}^k = \exists x \in \{x | x \in X_i \wedge e \in x\}. z_{i,x}^k$$



# モデル

友達が  $F_i^k$  で今までに  $X_i$  という発言をしてきたユーザー  $i$  の属性  $k$  が  $e$  である確率 .

Eq. 2

$$\Psi(z_{i,e}^k, X_i, F_i^k : \Theta) \propto \Psi_{\text{text}}(z_{i,e}^k, X_i) \times \Psi_{\text{Neigh}}(z_{i,e}^k, F_i^k)$$

右辺は、"テキスト的要因" と"隣人的要因" とに分離して独立と仮定している .

# テキスト的要因

エンティティ  $e$  と テキスト  $X_i$  から得る素性ベクトルを  $\psi_{text}(z_{i,e}^k, X_i)$  として、

$$\psi_{text}(z_{i,e}^k, X_i) = \exp [\Theta_{text}^k{}^T \cdot \psi_{text}(z_{i,e}^k, X_i)]$$

$\Theta_{text}^k$  は重みベクトル

# 隣人的要因

ユーザー  $i$  の友達  $j$  の発言  $X_j$  を見て、決める .

$$\psi_{Neigh}(z_{i,e}^k, F_i^k) = \prod_{j \in F_i^k} \Phi_{Neigh}(z_{i,e}^k, X_j)$$

where

$$\Phi_{Neigh}(z_{i,e}^k, X_j) = \exp [\Theta_{Neigh}^k{}^T \cdot \psi_{Neigh}(z_{i,e}^k, X_j)]$$

# 素性ベクトルの作り方

そんなに面白くない

- エンティティが大文字で始まるか
- エンティティの長さ
- POS tag
- エンティティの辞書にマッチする語がツイート中にあるかどうか

## 配偶関係の場合の隣人関係

本来、ユーザー  $i$  の配偶者が  $j$  なら

$$F_i^{Spouse} = \{j\}$$

だけど、分からない間はそうはいかないので、ツイート中に現れた Twitter ID 全ての集合を用いる .

# 推定のアルゴリズム

推定したいユーザーの周り ( $F_i^k$ ) の属性が既知の場合と分かってない場合 .

現実世界においては、部分的には既知であることがある .

- NEIGH-OBSERVED
- NEIGH-LATENT

# NEIGH-OBSERVED

周りの属性が既知なら、いきなり右辺が求まる.

$$z_{i,e}^k \leftarrow \operatorname{argmax}_z \Psi(z, X_i, F_i^k)$$

# NEIGHT-LATENT

入力  $\{(i, X_i, F_i^k)\}$

初期化 全ての  $z_{i,e}^k$  を  $\Psi_{text}$  で推定

更新 収束するまで  
for-each  $i, e$   
    ■  $z_{i,e}^k$  を  $\Psi$  で推定

$$z_{i,e}^k \leftarrow \operatorname{argmax}_z \Psi(z, X_i, F_i^k)$$

## Eq. 2 (再掲)

$$\Psi(z_{i,e}^k, X_i, F_i^k : \Theta) \propto \Psi_{text}(z_{i,e}^k, X_i) \times \Psi_{Neigh}(z_{i,e}^k, F_i^k)$$



# ベースライン

**Only-text** さっきので  $\psi_{text}$  しか使わない

**NELL** NELL<sup>a</sup>にある大学名と会社名のリストとマッチしたら true と答える  
 $z_{i,x}^k$  を当てる

---

<sup>a</sup><http://rtw.ml.cmu.edu/rtw/kbbrowser/>

# LOCALの実験

- LOCAL(ENTITY): Entity-level:  $z_{i,e}^k$  を当てるタスク (GLOBAL と同じ)
- LOCAL(TWEET): Tweet-level:  $z_{i,x}^k$  を当てる (サブ) タスク

# 結果

		GLOBAL			LOCAL(ENTITY)			LOCAL(TWEET)		
		P	R	F	P	R	F	P	R	F
Our approach	NEIGH-OBSERVED	<b>0.804</b>	<b>0.515</b>	<b>0.628</b>	<b>0.524</b>	0.780	<b>0.627</b>	<b>0.889</b>	0.729	<b>0.801</b>
	NEIGH-LATENT	0.755	0.440	0.556	0.420	0.741	0.536	0.854	0.724	0.783
<b>Only-Text</b>	—	0.735	0.393	0.512	0.345	0.725	0.467	0.809	0.724	0.764
<b>NELL</b>	—	—	—	—	0.170	<b>0.798</b>	0.280	0.616	<b>0.848</b>	0.713

Table 4: Results for Education Prediction

精度は GLOBAL > LOCAL

再現は GLOBAL < LOCAL — LOCAL において  $z_{i,e}^k$  は  $z_{i,x}^k$  の OR だから

		GLOBAL			LOCAL(ENTITY)			LOCAL(TWEET)		
		P	R	F	P	R	F	P	R	F
Our approach	NEIGH-OBSERVED	<b>0.643</b>	<b>0.330</b>	<b>0.430</b>	<b>0.374</b>	<b>0.620</b>	<b>0.467</b>	<b>0.891</b>	<b>0.698</b>	<b>0.783</b>
	NEIGH-LATENT	0.617	0.320	0.421	0.226	0.544	0.319	0.804	0.572	0.668
<b>Only-Text</b>	—	0.602	0.304	0.404	0.155	0.501	0.237	0.764	0.471	0.583
<b>NELL</b>	—	—	—	—	0.0079	0.509	0.0156	0.094	0.604	0.163

Table 5: Results for Job Prediction

- 「学歴」より難しい (学生はすぐ宿題の話をするので簡単)
- Only-Text < NEIGH-LATENT < NEIGH-OBSERVED から、隣人関係の有用性が言える

		GLOBAL			LOCAL(ENTITY)			LOCAL(TWEET)		
		P	R	F	P	R	F	P	R	F
Our approach	—	<b>0.870</b>	<b>0.560</b>	<b>0.681</b>	<b>0.593</b>	<b>0.857</b>	<b>0.701</b>	<b>0.904</b>	<b>0.782</b>	<b>0.839</b>
<b>Only-Text</b>	—	0.852	0.448	0.587	0.521	0.781	0.625	0.890	0.729	0.801

Table 6: Results for Spouse Prediction

# まとめ、感想

- 訓練データの作成には、属性ごとに工夫が必要
- 結果はそこまで属性によって偏らない